LegoNLP

une suite de scripts python pour l'analyse textuelle

Journée du 21 janvier 2025

L'atelier

Impact de l'IA sur les humanités, les SHS et l'éducation

- Les avancées récentes en IA ont eu un <u>impact</u> significatif sur divers domaines au sein des humanités et des SHS (littérature, journalisme, droit, musicologie, archéologie…).
- Ces innovations ont permis l'accès à de vastes ensembles de <u>données</u> numérisées, stimulant le développement des <u>outils</u> (recherche, enseignement et apprentissage).

Les données

- Cet atelier pratique vise à explorer le potentiel de ces technologies et outils émergents appliqués aux textes, bien que ces avancées s'appliquent également à d'autres types de données comme les images, les vidéos, les chiffres…

Data Processing Pipeline

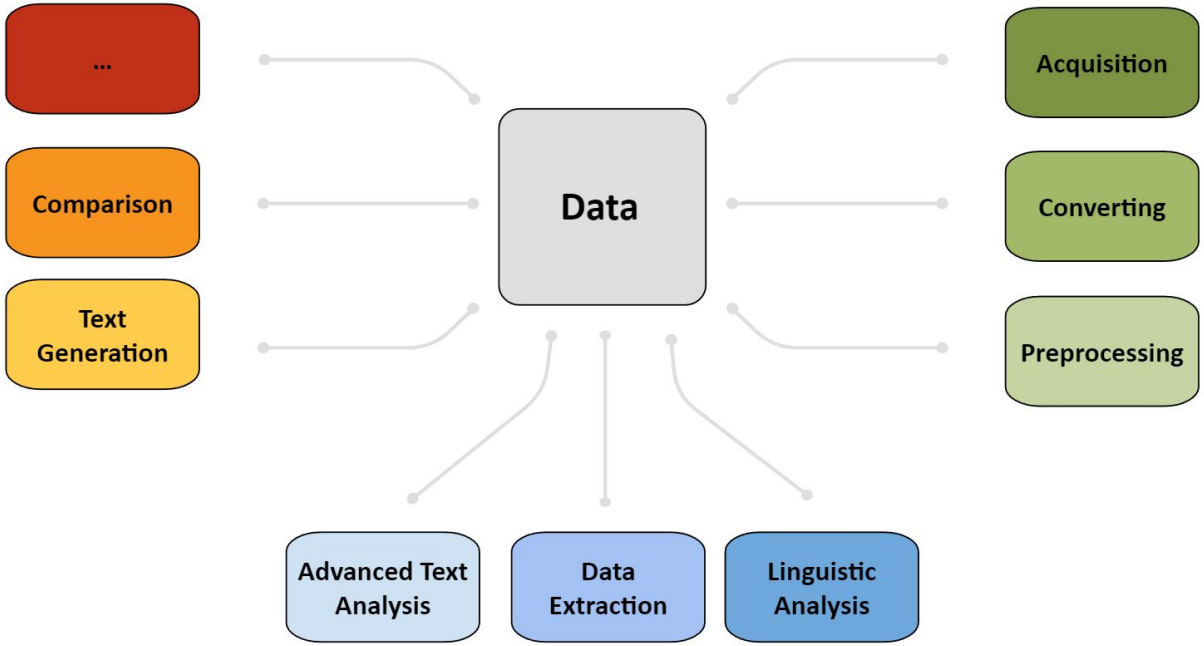

Distant & Close Reading

- La lecture attentive (Close Reading):
  - Privilégier le particulier par rapport au général, le singulier par rapport au global, en s'attachant aux mots, à la syntaxe, à la structure textuelle et à l'interaction du texte et de son lecteur…
- La lecture à distance (Distant Reading) est une approche des études littéraires qui applique des méthodes informatiques aux données littéraires volumineuses:
  - *Understanding literature not by studying particular texts,*
    but by aggregating and analyzing massive amounts of data (F. Moretti)

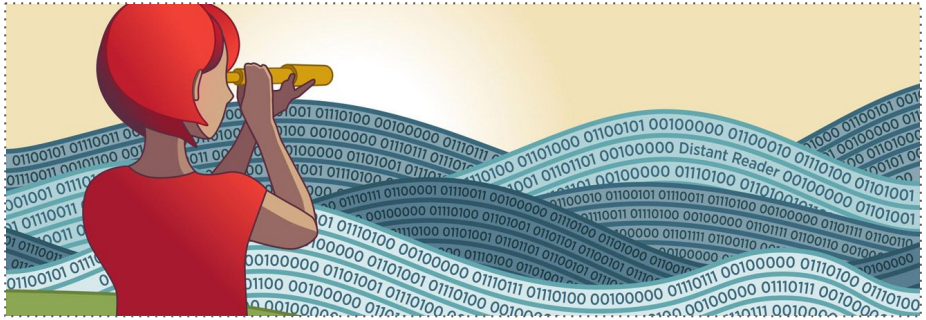

Différentes approches

- Approche orientée cas d'utilisation (top-down): les objectifs et contraintes souhaités sont bien établis, puis la technologie est conçue pour s'adapter à ces paramètres.

- Approche pilotée par les données (bottom-up): commencer avec les données et explorer la performance des différents outils disponibles.

→ Dans les deux cas: les résultats restent à évaluer et à interpréter par les spécialistes

Scénarios d'utilisation

Chercheur en littérature :

- Numérisation de corpus
- Analyse de la fréquence des mots et des motifs
- Identification des thématiques, des émotions et des entités nommées (EN)...
- Génération de résumés et simplification de texte
- Comparaisons de style à grande échelle
- Visualisation (cartographie et réseaux...)
- ...

Conservateur d'art :

- Archivage numérique pour la préservation du patrimoine culturel
- Création de métadonnées pour les éléments numérisés (date, source, détails historiques associés...)
- Intégration de la réalité augmentée ou virtuelle pour les objets d'art.
- Création de plateformes en ligne pour valoriser les collections numérisées.
- Création de stratégies de préservation à long terme: sauvegarde et sécurité des données.
- ...

Enseignant de langue :

- Apprentissage personnalisé : adaptation des textes, exercices interactifs, correction automatisée et tutorat personnalisé...
- Création d'environnements immersifs avec la réalité virtuelle et augmentée.
- Fournir des ressources multilingues pour soutenir les apprenants de divers horizons linguistiques.

Exemple de scénario

- Question de recherche ou une problématique: est-ce que les techniques IA nous aident à comprendre des corpus sans les lire directement ?
  - Avantages et limites
  - Articulation Distant et Close reading
- Sélectionner un corpus textuel, visuel, sonore, ou multimodal.
- Utiliser des outils et techniques d'analyse NLP & IA:
  - Lemmatisation, POS, stopwords…
  - Mots-clés et collocations…
  - Entités nommées, citations…
  - Sentiments…
  - Topics, résumé automatique…
  - Visualisations…
- Résultats, évaluation, interprétation

Exemple de scénario: Paris dans la littérature

Exemple de scénario: Paris dans la littérature

- Contexte :
  - Exploration des textes et documents historiques sur Paris.
  - Utilisation des technologies d’intelligence artificielle (IA) pour une analyse approfondie des données.

- Objectifs pédagogiques :
  - Acquérir des compétences pour collecter et structurer des données historiques.
  - Se familiariser avec les concepts de l'extraction d'information et de l'analyse sémantique.
  - Réaliser des cartes et des réseaux pour illustrer les relations et contextes.

- Outils mobilisés :
  - Environnement de programmation : Python (spaCy, NLTK, pandas…) et notebooks.
  - Techniques de traitement automatique du langage (NLP) et de géolocalisation.
  - Outils de visualisation : Gephi, Folium…

Déroulé de l’atelier

- Étape 1 : Collecte et prétraitement des données
  - Sources : Textes numérisés, archives, œuvres littéraires.
  - Méthodes :
    - Extraction automatisée avec des scripts Python (scraping et OCR).
    - Nettoyage des données (normalisation, encodage UTF-8, suppression des doublons).

- Étape 2 : Analyse des Entités Nommées (EN)
  - Objectif : Extraire et classer :
    - Lieux : Rues, monuments, quartiers de Paris.
    - Personnages : Écrivains, philosophes, figures historiques.
  - Outils : spaCy, flair, ou transformers pour les textes complexes.

- Étape 3 : Visualisation des Résultats
  - Cartographie : Localisation des lieux extraits (QGIS, Leaflet).
  - Analyse de réseaux : Relations entre personnages et lieux (Gephi, Python).

Résultats et applications

- Résultats attendus :
  - Cartes interactives : visualisation géographique de Paris à l’époque.
  - Graphes de réseaux : représentation des relations entre personnages, lieux et événements.
  - Interprétations narratives : compréhension enrichie des connexions dans les textes.

- Applications possibles :
  - Études littéraires et historiques.
  - Développement de ressources pédagogiques interactives.
  - Exploration numérique pour d'autres périodes ou thématiques.

Organisation générale

- Même thématique pour tout le monde
- Travail en groupe
- Présentation finale (exemple)

Atelier

- Approche pratique
- Débutants
- Python
- Bibliothèques prêtes à l'emploi et modèles Pré-entraînés
- Notebooks (Google Colab)

https://rb.gy/3zyqzk

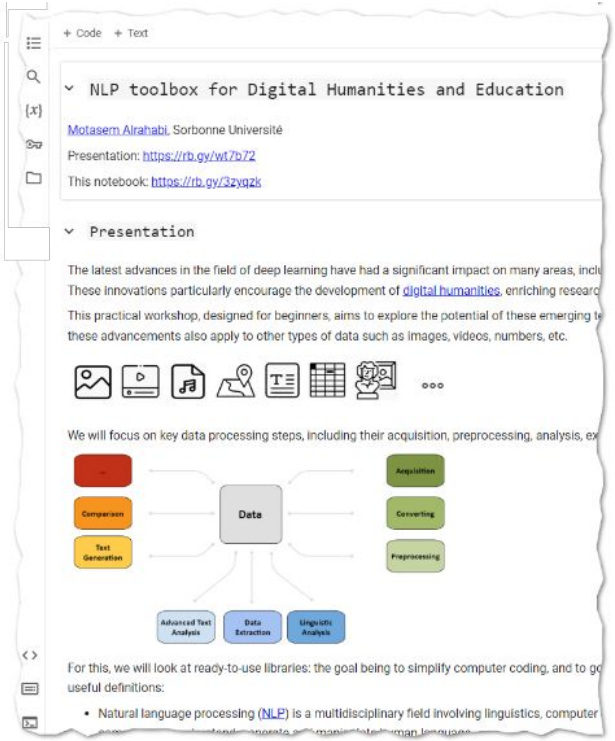

1. **Enregistrez une copie** du notebook sur votre Drive (menu Fichier)
2. Exécutez la première **cellule 0**, cela peut prendre un certain temps → nécessaires pour l'ensemble du notebook.
3. Exécutez les cellules qui vous intéressent dans l'ordre que vous souhaitez… Elles sont **indépendantes** les unes des autres.
4. Essayez de **personnaliser** le texte d'entrée dans chaque cellule, puis le modèle ou la langue…

Merci